

CATENA: Constrained Behavioral Reachability for Transactional Control in Finite Memory

외부 transaction demand와 내부 memory-control geometry의 정렬

연구계획서 v6.1 – post-E01 scientific revision

2026년 7월 26일

중심 질문. 외부 transaction이 요구하는 target update가 finite-memory controller의 실제 bounded control set 안에서 행동적으로 도달 가능한가? 그리고 그 reachability gap으로 correction과 unrelated-context retention의 오류를 episode 수준에서 예측할 수 있는가?

초록

Finite recurrent memory는 긴 이력을 고정 크기 state로 압축하지만, 외부 canonical state가 바뀐 뒤에도 이전 association과 그 파생 plan을 남길 수 있다. 최근 KV-cache erasure와 latent-state injection 연구는 “compact patch로 materialized state를 수정한다”는 일반적 해법을 빠르게 선점하고 있다[1]. 따라서 CATENA의 중심 novelty를 patch interface 자체에 두지 않는다. 본 연구는 verified transaction이 요구하는 이상적 update와 finite-memory update rule의 **constrained behavioral reachability** 사이의 관계를 분석한다. Unconstrained span regret, 실제 bounded gate set에서의 feasible regret, affected 및 unaffected readout을 통과한 behavioral regret를 분리하고, unseen geometry에서 learned error를 예측하는지 검증한다. 이어서 동일 two-output head를 diagonal subspace로 제한한 tied control과 independent erase/write control을 비교한다. H2는 positive difference-in-differences만으로 통과하지 않으며 asymmetric absolute gain, symmetric-operation equivalence, unaffected-retention non-inferiority, optimization robustness를 모두 요구한다. Channel-wise control의 한계는 단순 axis-rotation ablation이 아니라 demand-operator family의 joint diagonalizability로 이론화한다. 마지막으로 같은 base state에서 operation만 바꾼 counterfactual quartet에 dose, transplant, rescue를 적용하여 functional mediation을 검증한다. REALM confirmatory core는 H1–H4이며, operation label을 숨긴 held-out SUPERSEDE는 작은 external-validity anchor로만 사용한다. Multi-update assimilation과 Transformer/KVEraser boundary는 제출 이후 확장으로 분리한다.

Contents

1 연구 위치와 novelty boundary	3
2 형식적 문제 정의	3
2.1 State, transaction, update demand	3
2.2 OracleCandidate와 RecurrentRead	3
2.3 세 종류의 reachability regret	4
2.4 Correction과 retention	4
3 가설과 실험	5
3.1 H1: Constrained behavioral reachability	5
3.2 H2: Magnitude factorization	5
3.3 H3: Joint diagonalizability	6

3.4	H4: Functional mediation	6
3.5	H5-lite: Semantic anchor	6
3.6	H6와 RQ-T	7
4	실험 단계와 repository 매핑	7
5	현재 E00/E01 실행과 joint injection	7
6	통계와 claim gate	8
7	제출 범위와 일정	8
8	결과별 허용 주장	8
9	최종 메시지와 장기 확장	9

1. 연구 위치와 novelty boundary

KDA 계열은 recurrent memory의 decay와 active update를 제어하고, GDN2는 erase와 write를 channel-wise gate로 분리한다[2, 3]. CARVE는 저장된 content를 직접 읽지 않는 gate의 한계를 지적하고 state-conditioned update로 확장한다[4]. Transformer에서는 KVERaser가 이미 처리된 span의 KV influence를 learned steering state로 제거한다[1]. Knowledge editing의 ROME와 MEMIT은 parameter를 영구 수정한다는 점에서 다르지만[5, 6], activation/cache-level local repair는 CATENA와 직접 인접한다.

따라서 다음은 주장하지 않는다.

- 최초의 state patch, selective erase, erase/write decoupling 또는 controllability 분석을 제안한다.
- controlled associative probe만으로 recurrent LM 또는 agent architecture 전반의 우월성을 증명한다.
- mock/reference backend 결과를 pretrained-model evidence로 사용한다.

정확한 novelty. Verified transaction이 만드는 target-update family를 정의하고, finite-memory controller가 실제 bounded gate set에서 제공하는 local behavioral reachable geometry가 operation별 correction-retention error와 intervention sensitivity를 예측하는지 검증한다.

2. 형식적 문제 정의

2.1. State, transaction, update demand

Finite memory를 $S \in \mathbb{R}^{d_k \times d_v}$, transaction을 τ , controller freedom을 $g \in \mathcal{G}$ 라 둔다. 실제 update map은

$$S' = U(S, \tau, g),$$

환경이 요구하는 기준 상태는 $S^* = S + \Delta S^*$ 다. Controlled associative setting에서

$$A = k_j v_j^\top, \quad B = k_j v_{\text{new}}^\top$$

라 두면 네 operation은 다음 최소 demand를 갖는다.

Transaction	Erase	Write	ΔS^*
PRESERVE	0	0	0
ADD	0	1	$+B$
INVALIDATE	1	0	$-A$
SUPERSEDE	1	1	$-A + B$

ADD의 B 는 같은 semantic address에 추가되는 increment로 해석한다. Correlated new address sensitivity를 별도로 두어 특정 표현에만 유리한 task인지 확인한다.

2.2. OracleCandidate와 RecurrentRead

Magnitude factorization과 content interference를 분리한다.

OracleCandidate.

$$U_{\text{oracle}}(S, \tau, e, w) = S - eA + wB.$$

H1-H2의 순수 geometry claim은 이 조건에서만 열린다.




Figure 1: H1은 단순 rank가 아니라 bounded behavioral reachability를 검증한다.

RecurrentRead.

$$\hat{v}_j = k_j^\top S, \quad U_{\text{read}}(S, \tau, e, w) = S - e k_j \hat{v}_j^\top + w B.$$

Key correlation과 memory load가 높으면 $\hat{v}_j$ 는 다른 association을 포함한다. Oracle address k_j 는 여전히 주어지므로 두 조건의 차이를 addressing이 아니라 **candidate recovery/content interference**라 부른다.

2.3. 세 종류의 reachability regret

Local Jacobian은

$$J_g(S, \tau) = \frac{\partial \text{vec}(U(S, \tau, g))}{\partial g}$$

다. Coefficient 범위를 무시한 structural span regret는

$$R_{\text{span}}^2 = \min_{a \in \mathbb{R}^p} \frac{1}{D} \|\text{vec}(\Delta S^*) - J_g a\|_2^2.$$

하지만 실제 gate는 보통 $\mathcal{G} = [0, 1]^p$ 에 제한된다. 따라서 bounded feasible regret는

$$R_{\text{feas}}^2 = \min_{g \in \mathcal{G}} \frac{1}{D} \|U(S, \tau, g) - S^*\|_2^2$$

다. Scalar/dual-scalar TAMP에서는 box-constrained least squares로 정확히 계산한다.

State-space error가 미래 행동과 같지 않을 수 있으므로 affected 및 unaffected readout을 쌓은 W 를 둔다.

$$R_{\text{beh}}^2 = \min_{g \in \mathcal{G}} \frac{1}{D_W} \|W(U(S, \tau, g) - S^*)\|_2^2.$$

R_{span} 은 mechanism diagnostic, R_{feas} 는 bounded expressivity diagnostic, R_{beh} 는 H1의 confirmatory predictor다.

2.4. Correction과 retention

Affected readout 집합을 Q_{aff} , unaffected association을 I_{keep} 라 둔다.

$$E_{\text{corr}} = \frac{1}{|Q_{\text{aff}}|} \sum_{q \in Q_{\text{aff}}} \|r_q(S') - r_q(S^*)\|_2^2,$$

$$E_{\text{retain}} = \frac{1}{|I_{\text{keep}}|} \sum_{i \in I_{\text{keep}}} \|k_i^\top S' - k_i^\top S^*\|_2^2.$$

Affected key는 retention에서 제외한다. $\exp(-\text{MSE})$ harmonic joint는 Pareto plot의 secondary metric이며 confirmatory estimand가 아니다.




Figure 2: 직렬 claim chain은 $H1 \rightarrow H2 \rightarrow H4$ 다. H3는 병렬 이론 branch, H5는 anchor다.

3. 가설과 실험

3.1. H1: Constrained behavioral reachability

가설. OracleCandidate에서 operation fixed effect를 통제한 뒤에도 R_{beh}^2 가 unseen geometry의 learned behavioral MSE를 예측한다.

변수. Association load, key correlation, $\|A\|/\|B\|$, old/new cosine, candidate contamination을 episode 내부에서 변화시킨다. Train과 test geometry를 분리한다.

통계 모델.

$$E_{i,s}^{\text{learned}} = \alpha + \beta R_{\text{beh},i}^2 + \gamma_{\text{op}(i)} + u_s + \epsilon_{i,s}.$$

Primary는 unseen-geometry R^2 , calibration slope, seed-level positive-slope exact sign-flip다. State-span regret는 comparative diagnostic이다.

판정. OracleCandidate에서 예측력이 있어야 H1을 연다. RecurrentRead에서 추가되는 error는 candidate-recovery 및 content-interference gap으로 보고한다.

3.2. H2: Magnitude factorization

두 조건은 동일 two-output head $(\tilde{e}, \tilde{w})$ 를 사용한다. Tied만

$$(\tilde{e}, \tilde{w}) \mapsto (\beta, \beta), \quad \beta = (\tilde{e} + \tilde{w})/2$$

로 diagonal subspace에 projection한다.

H2는 다음을 모두 만족해야 한다.

1. ADD/INVALIDATE normalized absolute gain $> \delta_{\text{asym}}$;
2. PRESERVE effect CI $\subset [-\delta_P, \delta_P]$;
3. SUPERSEDE relative effect CI $\subset [-\delta_S, \delta_S]$;
4. asymmetric-minus-symmetric interaction > 0 ;
5. unaffected retention degradation $\leq \epsilon_{\text{ret}}$;
6. equal-budget validation tuning이 strict-recipe 방향을 뒤집지 않음.

Normalized gain은 최소 headroom을 넘는 episode에서 tied-to-oracle gap 중 dual이 낮은 비율이며 SESOI는 그 gap의 사전 고정 비율이다. Headroom이 지나치게 작은 episode는 사전 기준에 따라 normalized analysis에서 제외하되 raw MSE 표에는 남긴다. 8 paired training seeds를 사용한다. Episode paired bootstrap과 seed exact sign-flip($2^8 = 256$)을 분리한다.

3.3. H3: Joint diagonalizability

한 개의 common rotation은 representation basis로 흡수할 수 있다. 따라서 demand family 전체가 하나의 shared basis에서 동시에 diagonalizable한지가 핵심이다.

$$\kappa = \mathbb{E}_{i,j} \|P_i P_j - P_j P_i\|_F,$$

$$R_{JD} = \min_{Q^\top Q = I} \sum_{\tau} \|\text{offdiag}(Q^\top P_{\tau} Q)\|_F^2.$$

Family	Shared-basis property	예측
Axis commuting	현재 basis에서 diagonal	fixed diagonal 충분
Common-rotated commuting	공통 Q 에서 diagonal	learned basis가 회복
Noncommuting	공통 diagonal basis 없음	diagonal residual, low-rank 회복

Controller는 같은 demand descriptor를 받는다. Transaction-conditioned low-rank operator는 richer-control oracle upper bound로 명시하며, learned shared-basis diagonal과 동일한 의미의 parameter-matched model로 해석하지 않는다. Error와 active control dimension/parameter/FLOP frontier를 함께 보고한다.

3.4. H4: Functional mediation

E02의 8 paired-seed checkpoint를 freeze한다. 같은 S, A, B 에서 operation만 바꾼 counterfactual quartet을 사용한다.

Primary. Relevant intervention damage – irrelevant intervention damage의 operation interaction.

Support.

- gate dose 0, 0.25, 0.5, 0.75, 1의 monotonicity;
- independent same-operation donor와 같은 S, A, B 의 cross-operation donor를 gate norm에 맞춰 transplant;
- relevant gate zeroing 뒤 independent same-operation 또는 oracle gate로 relevant component만 복원하는 nontrivial rescue;
- post-hoc scalarization이 trained tied-vs-dual gap을 얼마나 재현하는지 mediation fraction으로 보고.

원래 gate를 그대로 되돌리는 것은 sanity check일 뿐 confirmatory rescue가 아니다.

3.5. H5-lite: Semantic anchor

Operation one-hot, oracle (e, w) , exact mask를 입력하지 않는다. Structured records에서 version, validity, prior/current relation을 읽는다.

Split	검증 대상
Held-out SUPERSEDE, seen domain/template	demand composition (primary)
Seen operation, held-out paraphrase	surface robustness
Seen operation, held-out domain	domain transfer
SUPERSEDE + new domain + paraphrase	combined stress

Primary는 oracle address + hidden old value이며 hidden address 조건과 동시에 claim하지 않는다. 300-item audit는 split/domain stratification, two independent reviewers, agreement, adjudication을 기록한다. Meaning preservation ≥ 0.95 , answer leakage ≤ 0.02 , reviewer agreement ≥ 0.80 을 모두 만족하기 전에는 semantic claim을 열지 않는다.

3.6. H6와 RQ-T

H6는 multi-update, plan continuation, repeated query에서 one-time assimilation, retrieve-every-query, retrieve-once cached snapshot을 quality-constrained cost로 비교한다.

$$m_q^* = \min\{m : C_{\text{assim}}(m) < C_b(m), E_{\text{corr}} \leq \epsilon_c, E_{\text{retain}} \leq \epsilon_r\}.$$

RQ-T는 KVEraser[1], typed append, suffix/full re-prefill을 operation-matched로 비교하지만 official revision과 localization parity가 확보될 때까지 workshop claim에 포함하지 않는다.

4. 실험 단계와 repository 매핑

단계	Entry point	산출물	역할
E00	e00_protocol_lock.py	기존 environment/protocol artifact	실행 중 변경 금지
E01	e01_local_controllability.py	기존 v6.0 pilot	confirmatory 아님
E01b	e01b_constrained_behavioral_reachability.py	per-episode regret/error, unseen calibration	H1
E02	e02_magnitude_factorization.py	8-seed tied/dual, raw metric, strict+tuned	H2
E03	e03_granularity_orientation.py	commutator, JD gap, operator frontier	H3
E04	e04_functional_mediation.py	dose/transplant/rescue	H4
E05	e05_semantic_demand_inference.py	OOD splits, audit CSV	H5 anchor
E06	e06_reusable_state_assimilation.py	chain, plan, quality break-even	extension
E07	e07_transformer_boundary.py	official backend only	extension
E08	e08_claim_freeze.py	evidence registry, claim tiers	필수

5. 현재 E00/E01 실행과 joint injection

현재 동작 중인 E00/E01의 fingerprint를 보존하기 위해 live repository를 수정하지 않는다. 두 run은 v6.0 pilot로 끝까지 보존하고, 종료 뒤 additive patch를 적용한다.

1. active process가 없음을 확인한다.
2. E00/E01 import closure의 hash를 확인한다.

3. E01b와 새 theory/data/model module을 추가한다.
4. E02-E08, config, docs만 교체한다.
5. compile, pytest, config audit, CPU dry-run을 수행한다.
6. E01b부터 confirmatory evidence를 생성한다.

Patch는 E00, E01, common runner와 해당 import closure를 한 개도 덮어쓰지 않는다.

6. 통계와 claim gate

Episode paired bootstrap은 고정 checkpoint의 test-set uncertainty를, seed exact sign-flip은 training replicate uncertainty를 측정한다. Episode 수를 늘려 seed uncertainty를 인위적으로 줄이지 않는다.

Hierarchical gatekeeping은 다음과 같다.

1. H1이 통과해야 H2 claim을 연다.
2. H2가 통과해야 H4 mediation claim을 연다.
3. H3는 별도 theory branch다.
4. H5는 exploratory anchor이며 audit가 완료돼야 한다.
5. H6/RQ-T는 workshop claim ceiling을 올리지 않는다.

7. 제출 범위와 일정

REALM short paper의 본문은 H1-H4를 중심으로 구성하고 H5는 작은 anchor만 포함한다.

시점	작업	종료 조건
E00/E01 종료 직후	patch + E01b smoke	frozen hash 유지, test PASS
Day 1	E01b main	OOS calibration artifact
Day 2-3	E02 8 seeds	five guardrails + raw JSONL
Day 3-4	E04 8 seeds	primary/support contrasts
Day 4	E03 theory	JD figure/table
Day 5	H5-lite	primary split + audit export
Day 6	E08 freeze	claim registry fixed
Day 7-9	clean rerun, paper, anonymization	submission bundle

8. 결과별 허용 주장

관찰	최대 허용 주장
H1만 통과	bounded behavioral reachability가 finite-memory update error를 예측한다.
H1+H2	independent erase/write magnitude가 asymmetric demand interference를 줄인다.
H3	diagonal control의 충분성이 demand family의 joint diagonalizability에 의존한다.
H1+H2+H4	factorization advantage가 operation-specific function으로 매개된다.
H5 방향+audit	structured semantic transaction의 작은 external-validity anchor.

DID만 양수
Zeroing만 양성
Mock E07

H2 금지; symmetric degradation artifact 가능성.
necessity diagnostic만 허용; mediation 금지.
Transformer systems claim 금지.

9. 최종 메시지와 장기 확장

Finite memory의 update 실패는 gate 수 자체가 아니라, environment가 요구하는 target-update family와 controller가 실제 bounded gate set에서 제공하는 behavioral reachable geometry의 rank, orientation, conditioning이 맞지 않을 때 발생한다. CATENA v6.1은 이를 constrained regret, factorization guardrail, joint diagonalizability, counterfactual intervention으로 검증한다.

후속 연구에서는 external state를 의미론적으로 명시적으로 유지하고 internal state는 dense하고 entangled한 채 update control만 softly addressable하게 만든다. Multimodal observation과 action-conditioned future prediction은 controlled core가 성립한 뒤 world-model 방향으로 확장한다.

References

- [1] Mufei Li, Shikun Liu, Dongqi Fu, Haoyu Wang, Yinglong Xia, Hong Li, Hong Yan, and Pan Li. “KVERaser: Learning to Steer KV Cache for Efficient Localized Context Erasing”. In: arXiv preprint arXiv:2606.17034 (2026). URL: <https://arxiv.org/abs/2606.17034>.
- [2] Kimi Team. “Kimi Linear: An Expressive, Efficient Attention Architecture”. In: arXiv preprint arXiv:2510.26692 (2025). URL: <https://arxiv.org/abs/2510.26692>.
- [3] Ali Hatamizadeh, Yejin Choi, and Jan Kautz. “Gated DeltaNet-2: Decoupling Erase and Write in Linear Attention”. In: arXiv preprint arXiv:2605.22791 (2026). URL: <https://arxiv.org/abs/2605.22791>.
- [4] Sayak Dutta. “CARVE: Content-Aware Recurrent with Value Efficiency for Chunk-Parallel Linear Attention”. In: arXiv preprint arXiv:2606.27229 (2026). URL: <https://arxiv.org/abs/2606.27229>.
- [5] Kevin Meng, David Bau, Alex Andonian, and Yonatan Belinkov. “Locating and Editing Factual Associations in GPT”. In: Advances in Neural Information Processing Systems. 2022.
- [6] Kevin Meng, Arnab Sharma, Alex Andonian, Yonatan Belinkov, and David Bau. “Mass-Editing Memory in a Transformer”. In: arXiv preprint arXiv:2210.07229 (2022). URL: <https://arxiv.org/abs/2210.07229>.